Proposta de Dissertação

Estudante

Nome

Pedro Miguel Marques Sousa

Número

8200831

Orientação[1]

Orientador

Professora Doutora Mariana Reimão Queiroga Valério De Carvalho

Instituição/Cargo

Professora Adjunta estg ipp

Co-Orientador (se aplicável)

Professora Doutora Ana Isabel Coelho Borges

Instituição/Cargo

Professora Adjunta estg ipp

Proposta

Título

Modelação de Episódios Recorrentes de Stress Financeiro em Empresas: Comparação entre Métodos Multi-Estado Clássicos e Técnicas de Deep Learning de Sobrevivência

Tipo[2]

Dissertação

Área

Ciência de dados aplicada às finanças

Descrição do Trabalho

Resumo

A previsão de eventos de stress financeiro e *default* empresarial é uma área fundamental na gestão de risco, crucial para a estabilidade do mercado e para a tomada de decisões inerentes à administração da empresa. Os métodos estatísticos tradicionais, embora amplamente utilizados, apresentam limitações na precisão e na capacidade de capturar a dimensionalidade deste problema (Gepp & Kumar, 2015).

Neste contexto, técnicas como *survival analysis* e os modelos de *machine learning* (ML) surgem como metodologias para criar modelos preditivos de maior precisão (Wang et al., 2019). Esta dissertação propõe

[1] Anexar declaração do(s) orientador(es) indicando aceitar orientar os trabalhos do estudante

[2] Apagar o que não interessa

a aplicação de modelos de ML e técnicas de *Survival Analysis* para a previsão da ocorrência de um evento de stress financeiro, assim como uma previsão temporal do mesmo, visando superar as limitações dos modelos tradicionais de classificação ao modelar explicitamente o risco ao longo do tempo. Será explorada a *performance* de modelos avançados, comparando-se o modelo de risco proporcional de Cox (*Cox Proportional Hazard*), que servirá como *baseline*. Os modelos alvo a estudar serão: as *random survival forests* (RSF) e suas variantes (como, *Accelerated Oblique RSF*), dada a sua superioridade demonstrada na previsão de médio e longo prazo, particularmente em PME (Pequenas e Médias Empresas) (Borges & Carvalho, 2024; Ptak-Chmielewska & Matuszyk, 2020). Adicionalmente, serão consideradas abordagens de *deep learning* para análise de sobrevivência (como, DeepHit), que evitam pressupostos paramétricos restritivos (Lee et al., 2018).

A *performance* preditiva dos modelos será rigorosamente avaliada através de métricas específicas para dados de sobrevivência (como o *Integrated Brier Score* e a estatística *C*). Por fim, e para garantir a interpretabilidade e rastreabilidade do modelo no contexto de decisão, serão aplicadas metodologias de *explainable AI* (XAI), complementando a análise da importância das variáveis na determinação dos fatores de risco. A literatura sugere que a inclusão de variáveis não financeiras (Yamanaka & Ohsato, 2025; Ptak-Chmielewska & Matuszyk, 2020), de *governance* (Alzayed et al., 2023) e de condições macroeconómicas (Wu & Cole, 2024) pode melhorar significativamente a precisão e estender o horizonte temporal da previsão. O principal contributo é o desenvolvimento e validação de um modelo de ML que oferece maior precisão e estabilidade na previsão do stress financeiro, com potencial aplicação à recorrência de eventos de stress (Zhou et al., 2022).

Objetivos e resultados esperados

Como objetivos temos: Operacionalizar o conceito de recorrência, implementar modelos clássicos, implementar modelos de ML avançados, incorporar variáveis multidimensionais, avaliação comparativa, interpretabilidade. Espera-se demonstrar que os modelos de Deep Learning e Random Survival Forests superam os métodos clássicos na previsão de eventos recorrentes, especialmente em horizontes temporais mais longos e na presença de relações não lineares complexas entre as variáveis macroeconómicas e a saúde financeira da empresa.

Plano de trabalho

O plano de trabalho inicia-se com a revisão da literatura, focada no aprofundamento teórico sobre modelos multi-estado, algoritmos de *Deep Learning* como o *DeepHit*, e os determinantes micro e macroeconómicos do stress financeiro. Seguidamente, proceder-se-á à recolha (via SABI — base de dados de empresas portuguesas e espanholas direcionada para a análise financeira) e pré-processamento de dados, que engloba a extração de dados financeiros, *governance* e de indicadores macroeconómicos (via INE — Instituto Nacional de Estatística), bem como a transformação destes dados para o formato necessário e tratamento dos mesmos. A fase de implementação de modelos dedicar-se-á ao treino das abordagens clássicas (Cox/PWP) e à implementação e otimização de hiperparâmetros dos modelos de *Machine Learning* (*Random Survival Forests* e *DeepHit*). Por fim, realizar-se-á a avaliação e análise dos resultados através da comparação de métricas de desempenho (como o *Brier Score* e o *C-Index*) e da análise de interpretabilidade. De forma transversal a todo o período, decorrerá a escrita da dissertação, com a redação progressiva dos capítulos e a consolidação da discussão e conclusões na fase final.

De seguida podemos ver o cronograma desenvolvido, a utilizar como suporte temporal e de tarefas:

Proposta de Dissertação

PREVISÃO TEMPORAL	PLANO DE TRABALHO
Revisão da Literatura (Mês 1-2)	Aprofundamento sobre modelos multi-estado, DeepHit, e determinantes micro/macro do stress financeiro.
Recolha e Pré-processamento de Dados (Mês 2-3)	Extração de dados financeiros e de *governance* (SABI/Orbis). Recolha de indicadores macroeconómicos(INE/Pordata) e tratamento de dados.
Implementação de Modelos (Mês 3-4)	Treino dos modelos clássicos (Cox/PWP). Implementação e otimização de hiperparâmetros dos modelos ML (RSF, DeepHit).
Avaliação e Análise (Mês 5)	Comparação de métricas de desempenho e análise de interpretabilidade (XAI).
Escrita da Dissertação (Mês 1-6)	Redação contínua dos capítulos, com foco final na discussão e conclusões no último mês.

Referências bibliográficas

Alzayed, N., Eskandari, R., & Yazdifar, H. (2023). Bank failure prediction: corporate governance and financial indicators. *Review of Quantitative Finance and Accounting*, *61*(2), 601–631.
Borges, A., & Carvalho, M. (2024). Short- and Long-Term Financial Distress Prediction in SMEs: A Survival Model Comparison. *Journal of Applied Statistics*, 1–25.
Gepp, A., & Kumar, K. (2015). Predicting financial distress: A comparison of survival analysis and decision tree techniques. *Procedia Computer Science*, *54*, 396–404.
Khashei, M., Etemadi, S., & Bakhtiarvand, N. (2024). A New Discrete Learning-Based Logistic Regression Classifier for Bankruptcy Prediction. *Wireless Personal Communications*, *134*(2), 1075–1092.
Lee, C., Zame, W. R., Yoon, J., & van der Schaar, M. (2018). DeepHit: A Deep Learning Approach to Survival Analysis with Competing Risks. In *The Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18)* (pp. 2351–2358).
Ptak-Chmielewska, A., & Matuszyk, A. (2020). Application of the Random Survival Forests Method in the Bankruptcy Prediction for Small and Medium Enterprises. *Argumenta Oeconomica*, *1*(44), 131–143.
Wu, Q., & Cole, R. A. (2024). Macroeconomic conditions and bank failure. *Journal of Forecasting*, *43*(5), 1212–1234.
Yamanaka, S., & Ohsato, T. (2025). A multi-task-type bankruptcy prediction method without using financial statements. *Japan Journal of Industrial and Applied Mathematics*, *42*, 1231–1244.
Zhou, F., Fu, L., Li, Z., & Xu, J. (2022). The recurrence of financial distress: A survival analysis. *International Journal of Forecasting*, *38*(4), 1100–1115.

Dissertações

Aspetos inovadores

Proposta de Dissertação

A literatura atual carece de artigos dentro deste domínio onde o foco seja a recorrência, mantendo também a multi dimensionalidade, como já abordada em trabalhos mais recentes. Sem esquecer mencionar o uso de tecnologias de ponta, nomeadamente técnicas de *machine learning*, ao invés de metodologias clássicas.

Conferências científicas na área da dissertação

EPIA (Conferência Portuguesa de Inteligência Artificial), **CISTI** (Conferência Ibérica de Sistemas e Tecnologias de Informação), **PFN** (Portuguese Finance Network), **ICDSA** (International Conference on Data Science and Applications) .